# Chapter 2. Descriptive Statistics

2025-09-10

# 기술 통계 vs. 추론 통계

## Descriptive statistics vs. Inferential statistics

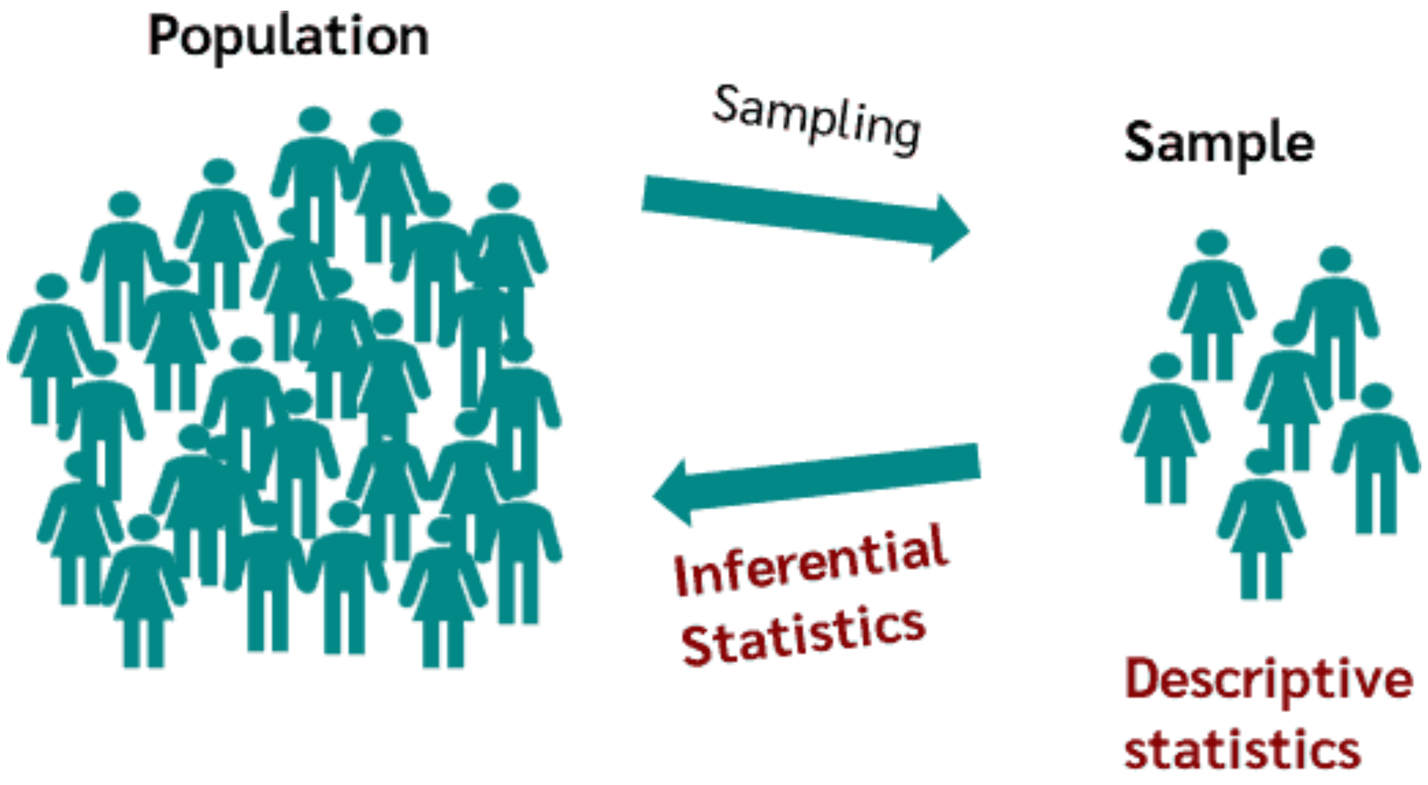

# 기술통계

왼) Guan WJ, Ni ZY, Hu Y, et al. Clinical Characteristics of Coronavirus Disease 2019 in China. *N Engl J Med*. 2020;382(18):1708-1720.
https://www.nejm.org/doi/full/10.1056/NEJMoa2002032
오) Choi JY, Kim S, Lee Y, Kim D, Lee W. Association Between Shift Working and Brain Morphometric Changes in Workers: A Voxel-wise Comparison. *Saf Health Work*. 2025;16(2):236-242.
https://www.sciencedirect.com/science/article/pii/S2093791125000113

## Descriptive statistics

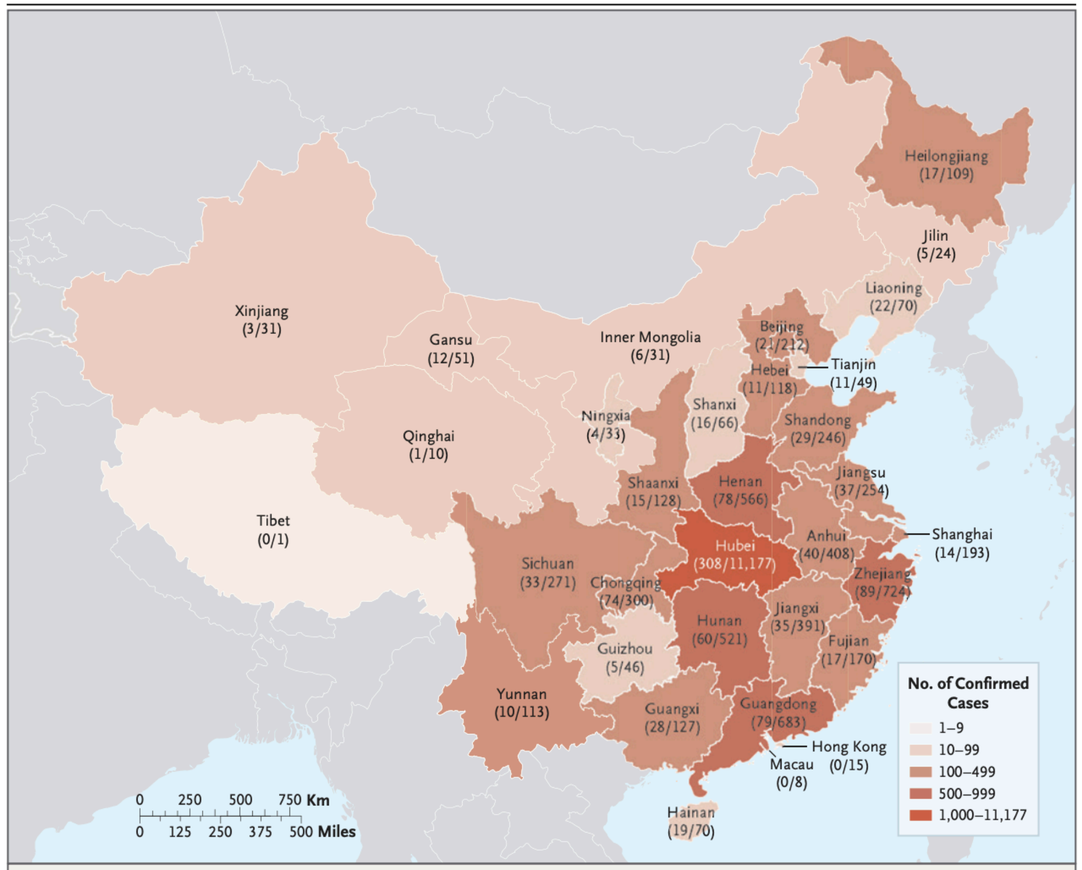


**Figure 1. Distribution of Patients with Covid-19 across Mainland China.**
Shown are the official statistics of all documented, laboratory-confirmed cases of coronavirus disease 2019 (Covid-19) throughout China, according to the National Health Commission as of February 4, 2020. The numerator denotes the number of patients who were included in the study cohort and the denominator denotes the number of laboratory-confirmed cases for each province, autonomous region, or provincial municipality, as reported by the National Health Commission.

Table 1. Baseline characteristics of study participants according to shift work

| Characteristic | Total ($n$ = 111) | Shift work | | Total ($n$ = 111) |
|---|---|---|---|---|
| | | No ($n$ = 79) | Yes ($n$ = 32) | |
| **Sex** | | | | |
| Male | 40 (36.0) | 28 (35.4) | 40 (36.0) | 0.8387 |
| Female | 71 (64.0) | 51 (64.6) | 71 (64.0) | |
| Age (years) | 36.11 ± 9.63 | 38.49 ± 9.74 | 36.11 ± 9.63 | 0.0001 |
| **Education level** | | | | |
| College or university | 40 (36.1) | 33 (41.8) | 40 (36.1) | 0.0490 |
| Graduate school or higher | 71 (63.9) | 46 (58.2) | 71 (63.9) | |
| **Dominant hand** | | | | 0.1481 |
| Right | 108 (97.3) | 78 (98.7) | 108 (97.3) | |
| Left or both | 3 (2.7) | 1 (1.3) | 3 (2.7) | |
| Job duration (years) | (8.31 ± 8.62) | (9.82 ± 9.43) | (8.31 ± 8.62) | 0.0002 |
| **Type of work** | | | | 0.9796 |
| Others | 46 (41.5) | 33 (41.8) | 46 (41.5) | |
| Nurse | 36 (32.4) | 25 (31.6) | 36 (32.4) | |
| Physician | 29 (26.1) | 21 (26.6) | 29 (26.1) | |

# 기술통계

## Descriptive statistics

- 데이터의 특성 및 분포를 이해하기 위해 데이터를 분석하고 요약
- 이상치를 식별하고 분석하는 데 도움을 주며 비정상적인 관측치나 데이터 수집 문제에 대한 유용한 통찰을 제공함
- (학술연구) 데이터의 특징, 추세 등에 대한 인사이트를 제공하며 연구 아이디어를 도출하고 추가 분석을 방향을 결정하는 데 도움
  - 연구 시 복잡한 통계 방법을 적용하기 전에 데이터를 이해할 수 있음
- (의사결정) 데이터 기반의 의사결정을 할 경우 이해관계자가 신뢰할만한 자료에 기반하여 결정을 내릴 수 있도록 함

## 🎲 응용통계학 중간고사 점수

| 번호 | 점수 | 번호 | 점수 | 번호 | 점수 | 번호 | 점수 | 번호 | 점수 |
|---|---|---|---|---|---|---|---|---|---|
| **1** | 58 | **11** | 41 | **21** | 59 | **31** | 45 | **41** | 76 |
| **2** | 62 | **12** | 86 | **22** | 60 | **32** | 78 | **42** | 79 |
| **3** | 24 | **13** | 56 | **23** | 69 | **33** | 71 | **43** | 12 |
| **4** | 93 | **14** | 100 | **24** | 55 | **34** | 66 | **44** | 38 |
| **5** | 35 | **15** | 92 | **25** | 87 | **35** | 49 | **45** | 77 |
| **6** | 64 | **16** | 80 | **26** | 52 | **36** | 83 | **46** | 84 |
| **7** | 88 | **17** | 73 | **27** | 70 | **37** | 90 | **47** | 65 |
| **8** | 89 | **18** | 68 | **28** | 81 | **38** | 96 | **48** | 72 |
| **9** | 94 | **19** | 74 | **29** | 91 | **39** | 44 | **49** | 83 |
| **10** | 63 | **20** | 85 | **30** | 98 | **40** | 82 | **50** | 39 |

from chatGPT 5

# 기술통계

## 순서에 따른 배열 (sorting)

- 데이터를 크기 순서로 나열
- 최소값, 최대값 👀

```
> dt$score
 [1]  58  62  24  93  35  64  88  89  94  63  41  86  56 100  92
[16]  80  73  68  74  85  59  60  69  55  87  52  70  81  91  98
[31]  45  78  71  66  49  83  90  96  44  82  76  79  12  38  77
[46]  84  65  72  83  39
```

```
> sort(dt$score)
 [1]  12  24  35  38  39  41  44  45  49  52  55  56  58  59  60
[16]  62  63  64  65  66  68  69  70  71  72  73  74  76  77  78
[31]  79  80  81  82  83  83  84  85  86  87  88  89  90  91  92
[46]  93  94  96  98 100
```

# Contents

1. 자료 분포의 요약 (Summary of data distribution)
2. 중심경향성 (Central tendency)
3. 변동성 (Variability)

# 1. 자료 분포의 요약

## Summary of data distribution

- **자료는 어떻게 생겼는가?**
  - 비슷한 값끼리 그룹화하고 각 그룹별 데이터를 요약
  - 데이터를 요약하는 과정에서 데이터에 포함된 정보를 잃어버릴 수 있음
- 관측값들을 그룹화 할 때는 같은 그룹에 포함된 관측값은 서로 유사
- 계급구간 정의: 각 그룹을 위한 실수구간을 정의하고 서로 겹치지 않게 정의함

# 1. 자료 분포의 요약

## Summary of data distribution

- 도수분포표
- 히스토그램, 도수다각형
- 줄기-잎 그림

# 1. 자료 분포의 요약

## 도수분포표 (Frequency distribution)

```
> sort(dt$score)
 [1]  12  24  35  38  39  41  44  45  49  52  55  56  58  59  60
[16]  62  63  64  65  66  68  69  70  71  72  73  74  76  77  78
[31]  79  80  81  82  83  83  84  85  86  87  88  89  90  91  92
[46]  93  94  96  98 100
```

- Sturges의 법칙
  - 계급구간(class interval)의 수 $k = 1 + 3.222(log_{10}n)$
  - 계급구간의 폭 $w = \dfrac{R}{k}$ ($R$은 range를 의미함)
- 예시) 50명의 응용통계학 점수 자료를 활용
  - 계급구간의 수: 1+3.222(log50) ≈ 6.474081
  - 계급구간의 폭 = $\dfrac{100 - 12}{6.5} \approx 13$

```
> 1+3.222*log10(50)
[1] 6.474081
```

```
> (100-12)/6.574081
[1] 13.3859
```

| class_interval | Freq |
|---|---|
| [12,25) | 2 |
| [25,38) | 1 |
| [38,51) | 6 |
| [51,64) | 8 |
| [64,77) | 11 |
| [77,90) | 14 |
| [90,103) | 8 |

# 1. 자료 분포의 요약

## 도수분포표 (Frequency distribution)

```
> sort(dt$score)
 [1]  12  24  35  38  39  41  44  45  49  52  55  56  58  59  60
[16]  62  63  64  65  66  68  69  70  71  72  73  74  76  77  78
[31]  79  80  81  82  83  83  84  85  86  87  88  89  90  91  92
[46]  93  94  96  98 100
```

| | 도수 | 누적도수 | 상대도수 | 누적상대도수 |
|---|---|---|---|---|
| **(10, 20]** | 1 | 1 | 0.02 | 0.02 |
| **(20, 30]** | 1 | 2 | 0.02 | 0.04 |
| **(30, 40]** | 3 | 5 | 0.06 | 0.10 |
| **(40, 50]** | 4 | 9 | 0.08 | 0.18 |
| **(50, 60]** | 6 | 15 | 0.12 | 0.30 |
| **(60, 70]** | 8 | 23 | 0.16 | 0.46 |
| **(70, 80]** | 9 | 32 | 0.18 | 0.64 |
| **(80, 90]** | 11 | 43 | 0.22 | 0.86 |
| **(90, 100]** | 7 | 50 | 0.14 | 1.00 |
| **합계** | 50 | 50 | 1.00 | 1.00 |

# 1. 자료 분포의 요약

## 히스토그램 (Histogram), 도수다각형 (Frequency polygon)

| | 도수 |
|---|---|
| (10, 20] | 1 |
| (20, 30] | 1 |
| (30, 40] | 3 |
| (40, 50] | 4 |
| (50, 60] | 6 |
| (60, 70] | 8 |
| (70, 80] | 9 |
| (80, 90] | 11 |
| (90, 100] | 7 |
| 합계 | 50 |

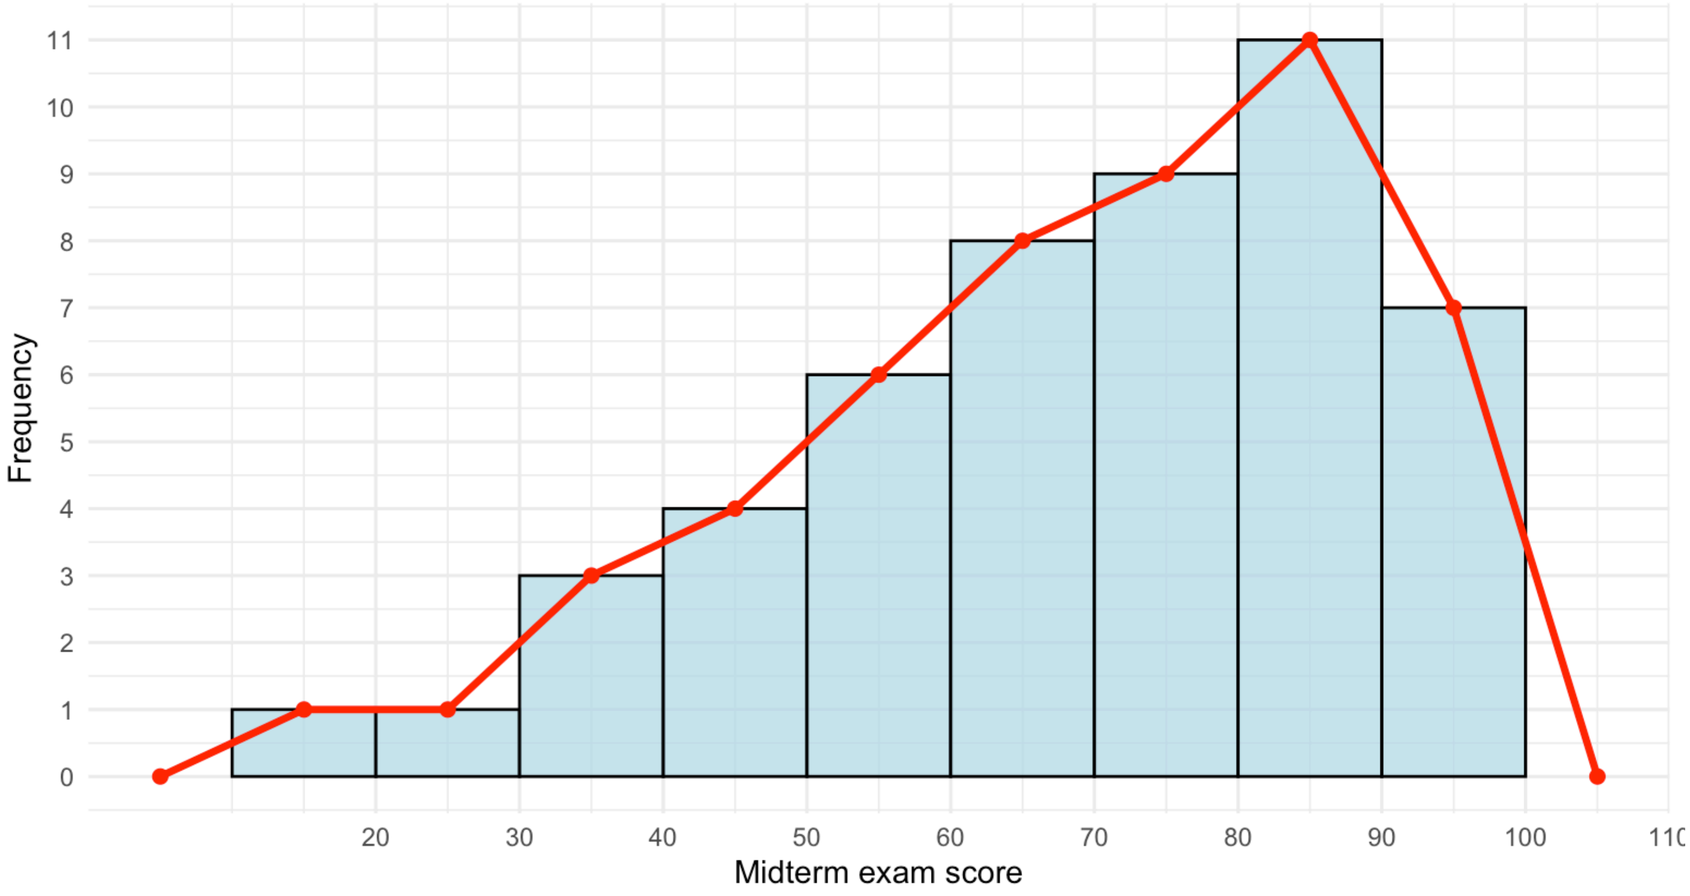

# 1. 자료 분포의 요약

## 줄기-잎 그림 (Stem-and-leaf displays)

```
> sort(dt$score)
 [1]  12  24  35  38  39  41  44  45  49  52  55  56  58  59  60
[16]  62  63  64  65  66  68  69  70  71  72  73  74  76  77  78
[31]  79  80  81  82  83  83  84  85  86  87  88  89  90  91  92
[46]  93  94  96  98 100
```

| 줄기 | | 잎 |
|---|---|---|
| 1 | \| | 2 |
| 2 | \| | 4 |
| 3 | \| | 589 |
| 4 | \| | 1459 |
| 5 | \| | 25689 |
| 6 | \| | 02345689 |
| 7 | \| | 012346789 |
| 8 | \| | 01233456789 |
| 9 | \| | 0123468 |
| 10 | \| | 0 |

- 히스토그램과 매우 유사하고 같은 목적으로 사용
- 관측값을 그대로 보여주기 때문에 실제값 알 수 있음
- 소량의 데이터셋을 다룰 때 효율적

# 2. 중심경향성

## Central tendency

- **자료의 중심이 어디인가?**
- **모수 (Parameter)**: 모집단으로부터 얻어진 기술통계량
- **통계량 (Statistics)**: 표본으로부터 계산된 기술통계량

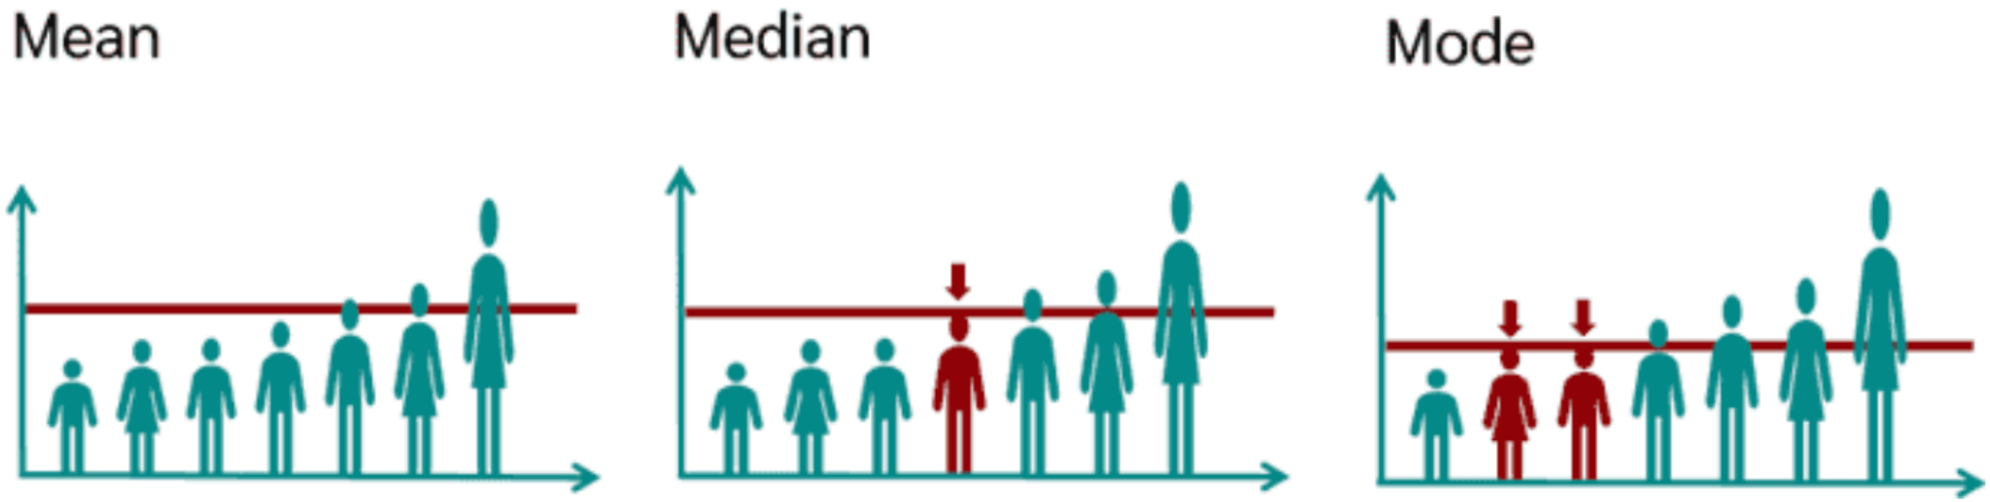

# 2. 중심경향성

## 평균 (Mean)

- 평균의 종류: 산술평균, 기하평균, 조화평균
- (산술) 평균: 모집단 또는 표본에 존재하는 모든 값을 더한 뒤에 그 측정값의 개수로 나눔
- 모평균 (Population mean) → $\mu = \dfrac{x_1 + x_2 + \ldots + x_N}{N} = \dfrac{\Sigma_{i=1}^{N} x_i}{N}$
- 표본평균 (Sample mean) → $\bar{x} = \dfrac{\Sigma_{i=1}^{n} x_i}{n}$

# 2. 중심경향성

## 평균 (Mean)

- (산술) 평균의 성질

  (1) 모든 데이터는 **오직 하나**의 산술평균을 갖는다 (uniqueness)

  (2) 산술평균은 그 의미를 이해하기 쉬우며 계산이 **간단**하다 (simplicity)

  (3) 산술평균은 모든 데이터를 이용하여 계산하기 때문에 **개별 값에 영향**을 받는다

    - 이상치 (outlier): 극단적으로 크거나 작은 값

# 2. 중심경향성

## 중위수 (Median)

- 표본 혹은 모집단이 유한인 경우, 데이터를 크기 순서대로 배열하였을 때 중앙에 위치한 값
  - n = 홀수: 가운데에 있는 관측값 ($\frac{n+1}{2}$번째 위치)
  - n = 짝수: 가운데에 있는 관측값 2개($\frac{n}{2}$, $\frac{n+1}{2}$번째 위치)의 평균

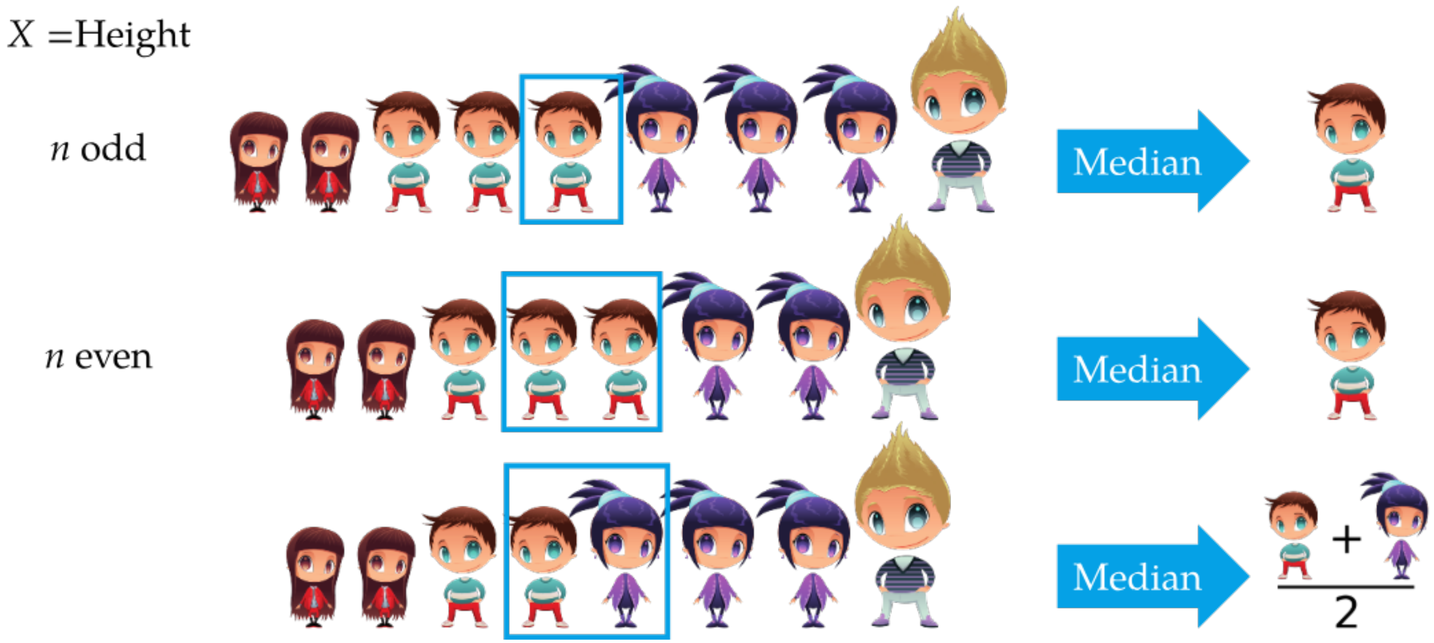


https://aprendeconalf.es/en/teaching/statistics/manual/descriptive-statistics/

# 2. 중심경향성

## 중위수 (Median)

- 중위수의 성질

  (1) 모든 데이터는 **오직 하나**의 중위수를 갖는다 (uniqueness)

  (2) 그 의미를 이해하기 쉬우며 계산이 **간단**하다 (simplicity)

  (3) 산술평균과 달리 **이상치에 덜 민감**하다 (robustness)

# 2. 중심경향성

## 최빈값 (Mode)

- 관측값 중 가장 빈도가 높은 값
  - 최빈값은 2개 이상 존재 할 수 있음 (유일성 X)

https://aprendeconalf.es/en/teaching/statistics/manual/descriptive-statistics/

# 2. 중심경향성

## Central tendency

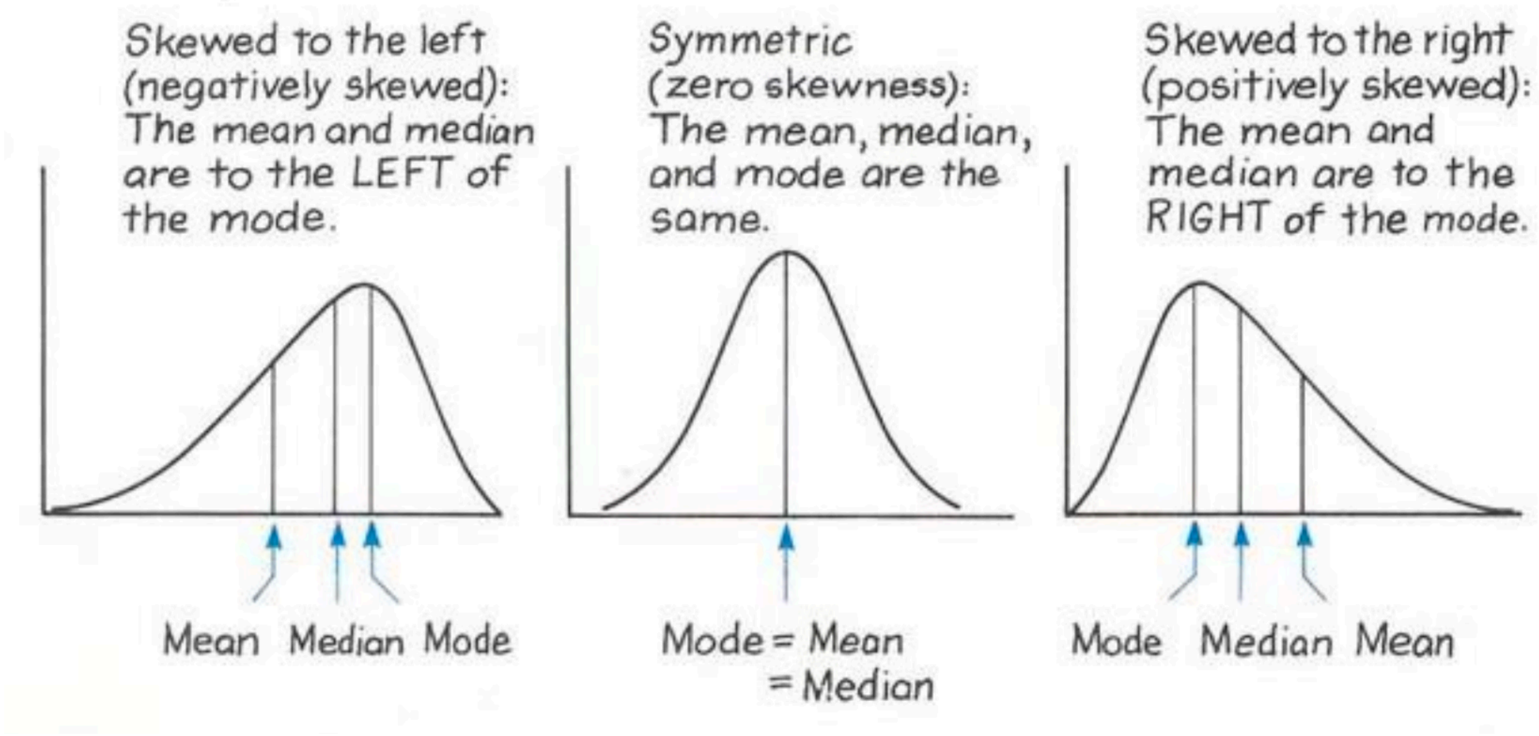


- 왜도 (skewness): 비대칭 정도를 의미

# 3. 변동성

## Variability

- **자료가 얼마나 퍼져 있는가?** 관측값들이 얼마나 다양한 값을 가질 수 있는가?

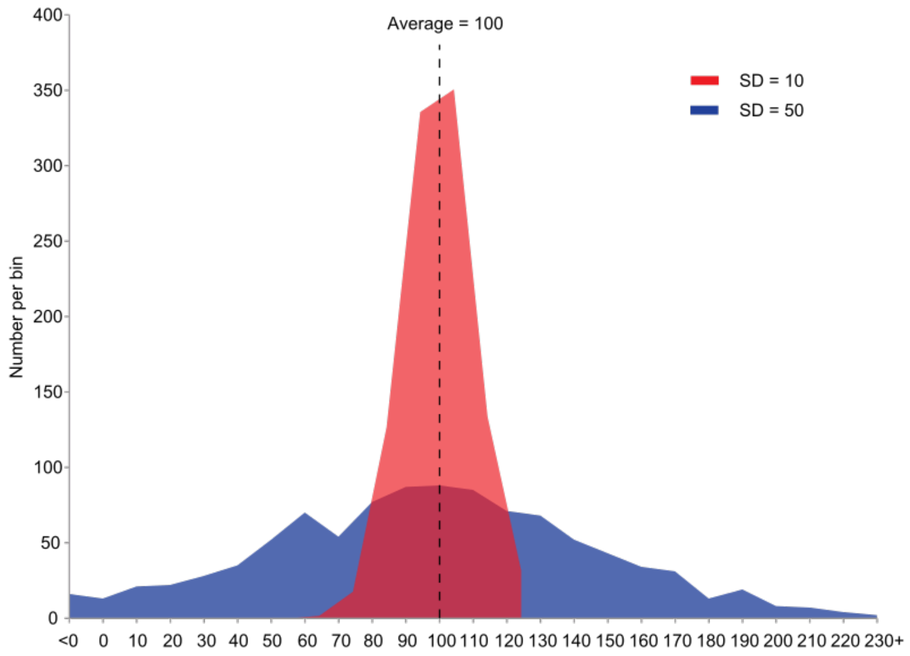


- 범위 (Range)
- 분산 (Variance), 표준편차 (Standard deviation)
- 순서통계량 (Order statistics)
- 첨도 (Kurtosis)

https://upload.wikimedia.org/wikipedia/commons/thumb/f/f9/Comparison_standard_deviations.svg/800px-Comparison_standard_deviations.svg.png

# 3. 변동성

## 범위 (Range)

- 관측값들의 최대값과 최소값의 차이로 정의
- $R = x_L - x_S$
- $[x_S, x_L]$의 형태로 최소값과 최대값을 보여주는 것이 더 효율적임

```
> sort(dt$score)
 [1]  31  32  33  35  37  39  40  41  43  44  45  46  48  53
[15]  55  56  58  59  61  62  63  64  66  67  69  70  71  72
[29]  74  76  77  78  79  80  81  83  84  85  86  87  88  89
[43]  90  91  92  93  95  96  97 100
```

# 3. 변동성

## 분산 (Variance), 표준편차 (Standard deviation)

- 평균에서 관측값이 얼마나 떨어져 있는지 측정, 편차 제곱의 평균
- 모분산 (Population variance) $\sigma^2 = \dfrac{\Sigma_{i=1}^{N}(x_i - \mu)^2}{N}$
- 크기가 $n$인 표본분산 (Sample variance) $s^2 = \dfrac{\Sigma_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$
  - 왜 분모가 $n-1$일까?
    - 관측 수 $n$으로 나누면 분산이 과소추정되므로 자유도(Degree of freedom) $n-1$로 나눔

      (자유도: 모수에 대한 정보를 주는 독립적인 관측값의 수를 의미)

# 3. 변동성

## 분산 (Variance), 표준편차 (Standard deviation)

- 표준편차 (Standard deviation) - 모표준편차 $(\sigma)$, 표본표준편차 $(s)$
  - $\sigma = \sqrt{\frac{\Sigma_{i=1}^{N}(x_i - \mu)^2}{N}}, s = \sqrt{\frac{\Sigma_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$
- 변동계수 (Coefficient of variation) $C.V. = \frac{s}{\bar{x}}(100)\,\%$
  - 서로 다른 두 데이터의 산포를 비교할 때 상대적 변동을 비교
  - 평균과 표준편차는 측정 단위가 같으므로 측정단위 영향을 제거할 수 있음

# 3. 변동성

## 순서통계량 (Order statistics)

- $n$개의 관측값 $x_1, x_2, \ldots, x_n$에서 $r$번째 순서통계량을 $x_{(r)}$로 표기함
  - $x_{(1)}$은 최소값, $x_{(n)}$은 최대값을 의미
- 사분위수(quantile)
  - 1사분위수(first quartile, $Q_1$): 25% 백분위수
  - 2사분위수(second quartile, $Q_2$): 50% 백분위수 = 중위수
  - 3사분위수(third quartile, $Q_3$): 75% 백분위수
- 사분위범위(Interquartile range) $IQR = Q_3 - Q_1$

**Box-and-whisker plot**

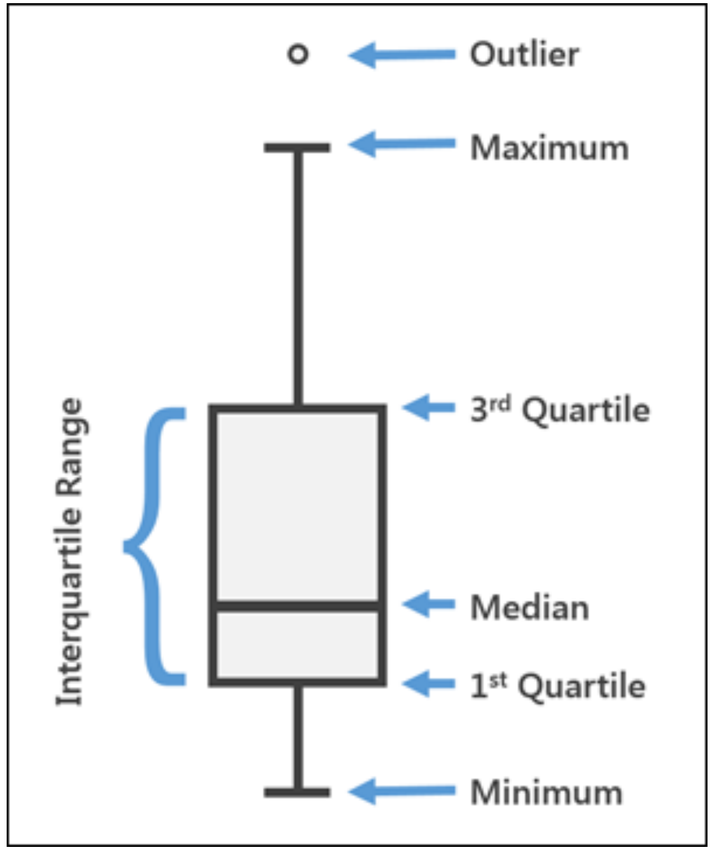


http://www.kwangsiklee.com/wp-content/uploads/2018/04/boxplot.png

# 3. 변동성

## 첨도 (Kurtosis)

- 종형으로 생긴 정규분포에 비하여 분포가 상대적으로 좀 더 뾰족(peaked)한지 혹은 편평(flat)한지에 대한 정도를 측정하는 기술통계량
  - 저첨(platykurtic): 평균 집중도가 적음
  - 중첨(mesokurtic): 정규분포와 비슷
  - 극첨(leptokurtic): 평균 집중도가 높음

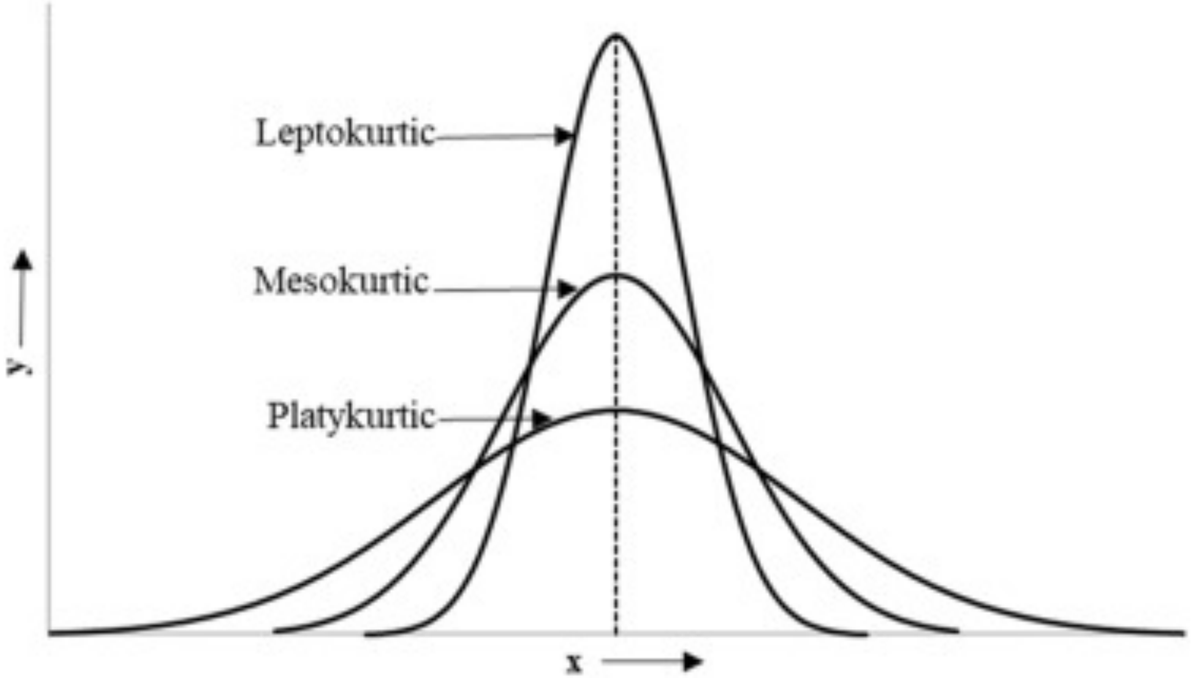


https://www.sciencedirect.com/topics/social-sciences/kurtosis